SKT ALEPH · T10 실증 연구

근거 제한 프롬프트는 미확인 안내를 줄이는가?

가상 기업교육 문의 20 쌍의 A/B API 실험

작성자 김윤아
작성일 2026 년 11 월 5 일
관심 분야 AI 에이전트 · 기업교육 운영 · 서비스 품질 검증

초록

공식 자료 밖의 내용을 추측하지 말라는 규칙이 AI 교육 문의 답변의 근거 없는 안내를 줄이는지 살폈다. 가상 안내문 10 항목과 질문 20 건을 고정하고 일반 조건 A 와 근거 제한 조건 B 를 각각 한 번씩 호출했다. 사용자가 수집한 성공 응답 40 개를 AI 보조 판정으로 분석한 결과, 근거 없는 절차 단정은 A 3/20(15%), B 2/20(10%)이었다. 알려진 부분의 정확성과 미확인 부분의 보류는 두 조건 모두 각각 12/12 였다. 경계 사례를 넓게 또는 좁게 해석하면 A/B 차이는 모두 0%p 가 되었다. 따라서 기본 결과의 방향은 가설과 일치하지만, 이 소표본에서 규칙의 안정적 우위를 확인했다고 결론내리지 않는다.

핵심어: 근거 기반 답변, 프롬프트 비교, 답변 보류, 운영 절차, 재현성

분석 단위	수집 결과	자료 범위
20 개 질문 쌍	40 개 성공 + 1 개 실패 시도	사용자 제공 API 로그
A 20 / B 20	동일 입력문·생성 설정 확인	과거 수동·다른 모델 자료 제외
주요 해석		
“모르는 정보는 모른다”고 답해도, 답변 뒤에 문서에 없는 “추후 안내하겠다”는 절차를 덧붙일 수 있었다. 불확실성 표현과 답변 전체의 근거 충실도는 구분해서 평가해야 한다.		

자료 수집: 2026.11.04 23:00:18 ~ 2026.11.05 09:21:27 (KST, 중단 포함).
이 논문은 자동 분석만으로 전체 서비스의 안전성이나 일반적 성능을 보증하지 않는다.

1. 서론: 질문을 가설로

MOA 는 기업교육 운영 문의에 공식 자료를 바탕으로 답변 초안을 제공하려는 서비스다. 앞선 작업에서 공식 문서에 없는 메뉴가 제안되는 문제를 연구 동기로 삼았다. 이번에는 단일 수정 사례를 일반화하지 않고, 같은 자료와 질문에서 근거 제한 규칙 유무만 비교하도록 범위를 좁혔다. 가상 자료를 사용했으므로 실제 교육기관의 정책이나 교육생의 개인정보는 포함하지 않았다.

1.1 검토한 후보와 선택 이유

후보 질문	선택 또는 접은 이유
① 추측 금지 규칙이 오류를 줄이는가	최종 선택: 같은 문의에서 규칙 유무를 비교할 수 있음
② 답변에 출처를 요구하면 정확해지는가	출처 표시라는 별도 조작을 분리하기 위해 제외
③ 확인 필요 분류가 추측을 줄이는가	독립 주제 대신 B 의 복합 규칙에 포함
④ 프롬프트가 길수록 정확해지는가	길이와 지시 내용의 효과가 섞이므로 제외
⑤ 복잡한 질문일수록 추측이 늘어나는가	별도 가설 대신 혼합형 질문으로 일부 반영
⑥ 반복할 때 답변이 일관적인가	문항당 추가 반복이 필요하여 이번 범위에서 제외
⑦ 모델별 오류율이 다른가	모델 비교가 아닌 규칙 비교에 집중
⑧ 검색 결합(RAG)이 오류를 줄이는가	검색 성능까지 통제해야 하므로 제외
⑨ 사용자 만족도가 높아지는가	참여자 모집과 별도 조사 설계가 필요해 제외
⑩ 답이 없는 질문을 구별하는가	별도 주제 대신 보조 지표로 유지

1.2 최종 가설과 반박 가능한 결과

H1: 동일한 공식 안내자료와 동일한 교육생 문의를 제공했을 때, 문서에 없는 정보를 추측하지 말라는 규칙을 추가한 B 조건은 일반 안내 A 조건보다 근거 없는 구체적 안내를 포함한 답변 비율이 낮다.

규칙 유무가 답변별 오류(0/1)에 영향을 주는지를 조건별 오류 건수/20 과 질문별 A/B 쌍으로 측정한다. B 가 A 와 같거나 더 높으면 예측과 일치하지 않는다. B 가 조금 낮더라도 작은 표본과 판정 경계의 영향이 크면 확정적 효과 주장으로 이어가지 않는다.

AI 와 함께 막연한 “답변이 좋아지는가”를 메뉴·날짜·정책·절차의 근거 유무로 좁혔고, 무조건 답변을 보류하는 전략이 유리하지 않도록 알려진 부분의 정확성을 함께 보았다. 사용자는 주제를 선택하고 이후 수동 입력 부담을 줄이는 자동 수집을 요청했다.

2. 방법: 문헌과 실험 설계

2.1 선행연구와 이번 연구의 구분

Madhusudhan 외(2025)는 답변 가능·불가능 질문을 구분하여 보류 능력을 평가하고 엄격한 프롬프트 등의 영향을 실험했다[1]. 이는 규칙 유무를 조작할 근거이지만, 현재 한국어 교육 문의에서 B 가 우수하다는 증거는 아니다.

Peng 외(2025)는 네 데이터셋의 RAG 구성·프롬프트를 비교하며, 답할 수 있는 질문의 정확성과 답할 수 없는 질문의 보류를 함께 평가했다[2]. 이번 연구도 두 측면을 나누되, 검색기를 사용하지 않고 고정 안내문을 직접 제공하므로 해당 RAG 실험의 직접 재현은 아니다.

문헌 확인: 2026.11.05 ACL Anthology 공식 페이지의 제목·저자·연도·학회·쪽수·초록을 확인했다. 세부 표나 원문 전체를 검토한 것으로 쓰지 않았다. 채택한 학술 문헌은 2 편이며 검토 후 제외한 학술 문헌은 없다.

2.2 바꾸는 조건과 고정하는 조건

구분	설계 및 실제 로그에서 확인한 내용
독립 변수	A: 일반 안내 / B: 추측 금지와 확인 필요 표시 규칙을 함께 추가
자료·질문	F01~F10 의 가상 안내문, 한국어 질문 20 건: S 8 / U 8 / M 4
반복·단위	질문마다 A 1 회·B 1 회. 20 쌍이 비교 단위이며 같은 질문을 20 회 반복한 실험은 아님
모델	요청값과 API 응답 modelVersion 모두 gemini-3.5-flash-lite
설정	temperature=0, maxOutputTokens=2048. 그 밖의 서버 기본값·시드는 명시적으로 고정하지 않음
입력·순서	이전 대화 없는 user 메시지 1 개. 홀수 A→B / 짝수 B→A. 무작위 순서는 아님
형식	두 조건 모두 친절한 한국어 2~4 문장. B 의 추가 규칙 외 본문은 동일

2.3 측정값과 분모

측정값	판정 기준	분모
주지표: 근거 없는 안내	문서 밖의 구체적 사실·정책·절차 단정이 하나라도 있으면 1	조건별 20
알려진 부분 정확성	S/M 의 문서가 제공하는 핵심 부분을 정확히 답하면 1	조건별 12
미확인 부분 보류	U/M 에서 알 수 없는 요구값을 확정하지 않고 부재·확인 필요를 밝히면 1	조건별 12
형식·표현(사후 보조)	문장 수, “정보 확인 필요” 정확 문자열 및 의미상 변형을 분리 집계	별도 표시

S: 답변 가능, U: 자료만으로 답변 불가, M: 일부만 답변 가능. S/M 과 U/M 의 12 문항은 M 4 개가 겹치므로 합계 표본으로 더하지 않는다. B 는 길이도 늘어난 복합 조작이어서 개별 규칙만의 효과를 분리할 수 없다.

2. 방법: 실행·자료 보존·판정

2.4 수집 변경과 실제 실행

시점·단계	변경 및 보존
기존 수동 실험	Q01~Q04 8 응답과 Q09 파일럿 2 응답은 별도 보관. 현재 본분석에서 제외
최초 API 모델	gemini-3.1-flash-lite 에서 11 개 수집 후 503 반복을 사용자가 보고. 그 상세 원자료는 이번 업로드에 없으며 분석에 혼합하지 않음
새 모델의 별도 회차	gemini-3.5-flash-lite 로 Q01 부터 재수집. 질문·안내문·A/B 입력문은 유지
11/4 23:00~23:31 KST	33 개 성공 후 Q17-B 에 URLError 발생. HTTP 상태와 응답 본문이 없어 세부 원인은 미확정
11/5 09:18~09:21 KST	동일 설정으로 Q17-B 와 이후 6 개를 완료. 이미 성공한 33 개를 다시 생성하지 않음
최종 분석 포함	41 행 중 관측 성공 40 행 포함, 응답 없는 실패 1 행은 품질 분모에서 제외하되 원본에 보존

원자료는 사용자가 PC 에서 수집해 제공한 요청·응답 기록이다. 분석 시 추가 API 호출은 하지 않았다. 모든 성공 응답의 prompt_sha256 이 원래 입력문 40 개와 일치했고, 요청 본문은 해당 입력문 한 개뿐이었다. API 가 반환한 텍스트와 raw_answer 도 모두 일치했다. 실패한 Q17-B 를 재개한 것을 제외하면 성공 응답 중 교체·중복은 없었다.

수집 당시 included_in_current_paper=false 는 초기 탐색 패키지의 기본 필드였다. 원본 바이트는 수정하지 않고 final_analysis_manifest.json 에 최종 포함 행을 명시했다. 두 원본 파일의 SHA-256 과 입력문 해시는 재현 코드에서 검사한다. 원자료의 실패 행은 34 행, 재개 성공은 35 행이다.

2.5 의미 판정의 적용과 한계

의미 채점은 AI 가 원래 기준을 참고해 수행했다. 별도의 사람 간 일치도 검사는 없으며 A/B 조건을 가리지 않았다. 따라서 원 설계의 “사람이 채점”을 독립적으로 수행했다고 주장하지 않는다. 응답별 원문·인용 근거·판정 이유를 모두 공개하고, 계산 재현과 의미 판정의 신뢰도를 구분한다.

기본 판정에서는 “추후 안내해 드리겠다”는 시행 약속을 자료에 없는 절차 단정으로 포함했다. 반면 “공지가 올라오면 확인해 달라”는 조건부 권고는 시행 약속으로 보지 않았다. F10 은 교육 일정 변경의 채널만 규정하므로 최종 프로젝트 세부 정보 전체에 공지사항 안내를 약속할 근거는 없다.

향후 안내 약속과 조건부 권고의 세부 경계는 응답을 본 뒤 구체화했다. 이를 사전등록된 규칙이라고 소급하지 않고 넓은·좁은 해석을 함께 제시했다. 모든 변경은 protocol/change_log.md 에 기록했다. 원 가설 문장은 그대로 유지했다.

3. 결과

3.1 기본 비교

지표	A 일반	B 근거 제한
근거 없는 구체적 안내 포함	3/20 (15%)	2/20 (10%)
알려진 핵심 부분 정확성 (S/M)	12/12 (100%)	12/12 (100%)
질문의 미확인 부분 보류 (U/M)	12/12 (100%)	12/12 (100%)
2~4 문장 형식	20/20 (100%)	20/20 (100%)

주지표의 차이(A-B)는 5%p 로, 기본 판정에서는 가설과 같은 방향이었다. 그러나 이 차이는 Q02 한 쌍에서만 생겼다. 나머지는 두 조건 모두 오류 없음 17 쌍, 두 조건 모두 오류 있음 2 쌍(Q11·Q18)이었다. B 만 오류인 쌍은 없었다. 이 수치를 통계적으로 유의한 효과나 동등성의 증거로 해석하지 않는다.

질문 유형	A 오류 / 질문 수	B 오류 / 질문 수
S: 답변 가능	1/8	0/8
U: 자료만으로 불가	1/8	1/8
M: 일부 가능	1/4	1/4

질문이 요구한 알 수 없는 팀원 수·발표 일시·수수료 등은 두 조건 모두 임의로 제시하지 않았다. 다만 알려진 부분을 맞히거나 질문의 미확인 부분을 보류한 뒤에도 다른 근거 없는 절차를 덧붙일 수 있어 주지표와 보조 지표가 동시에 1 이 될 수 있다.

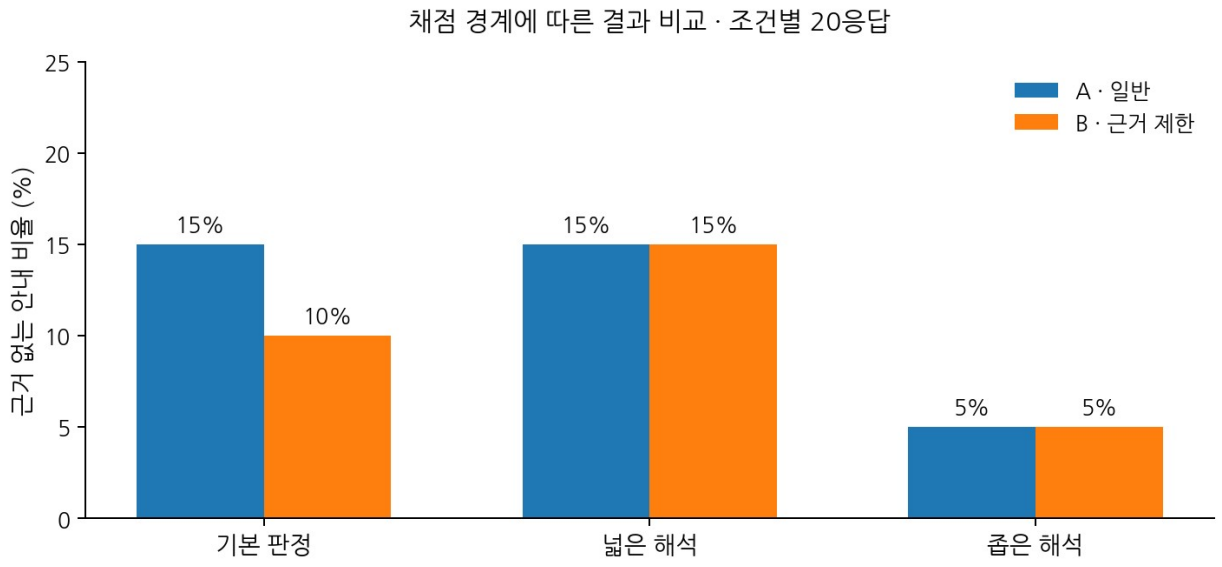


그림 1. 동일한 40 응답에 판정 경계를 달리 적용한 사후 민감도 분석. 넓은 해석은 B-Q02 의 공지사항 권고를 포함하고, 좁은 해석은 구체 채널을 확정한 안내만 남긴다. 새로운 응답을 생성하거나 기존 응답을 제외한 결과가 아니다.

3. 결과: 오류와 경계 사례의 원문

기본 판정에서 표시한 다섯 응답과 유일한 A/B 차이를 바꾸는 경계 문장을 모두 아래에 실었다. “근거 없음”은 실제 운영 정책이 거짓이라고 단정하는 뜻이 아니라, 이번에 제공한 안내문으로 확인되지 않는다는 뜻이다.

응답	실제 응답 중 해당 문장	판정과 이유
Q02 A 오류 1	관련 내용이 확정되면 별도로 안내해 드리겠습니다.	F02 는 미정리만 명시. 별도 안내 시행 약속은 없음. 좁은 해석에서는 제외
Q11 A 오류 1	추후 관련 내용이 정리되면 공지사항을 통해 안내해 드리겠습니다.	최종 프로젝트 내용을 공지사항으로 제공한다는 약속. F10 의 일정 변경 범위를 확대
Q11 B 오류 1	세부 진행 방식이 확정되면 추후 안내해 드리겠습니다.	정보 확인이 필요하다고 한 뒤에도 향후 안내 시행을 약속. 좁은 해석에서는 제외
Q18 A 오류 1	추후 관련 내용이 정리되면 공지될 예정이니 조금만 기다려 주시기 바랍니다.	미확인 인원수는 만들지 않았지만 향후 공지 예정이라는 절차를 추가
Q18 B 오류 1	추가로 확인되는 사항이 있으면 공지사항 등을 통해 안내해 드리겠습니다.	프로젝트 정보 전체를 공지사항 채널로 확대하여 안내를 약속
Q02 B 기본 0 넓은 해석 1	추가 안내가 나오는 대로 공지사항 등을 통해 확인 부탁드립니다.	기본: 조건부 확인 권고. 넓은 해석: 근거 없는 채널 유도로 포함

출처: data/raw/responses.jsonl 의 Q02·Q11·Q18 성공 응답. 응답 전체와 원자료 행 번호는 scoring/채점근거_전체.md 및 adjudication.csv 에서 확인한다.

3.2 비교를 바꾸지 않은 추가 관찰

A-Q12 의 “추후 관련 공지가 올라오면 확인 부탁드립니다”는 공지 시행을 약속하지 않는 조건부 권고로 0 을 유지했다. Q15 A/B 의 개인 출결 관련 서두는 수료 기준 질문에 다소 불필요했지만, 최소 출석일수 자체를 만들지는 않아 주지표 오류로 세지 않았다.

B 는 U/M 12 문항 모두에서 “정보 확인이 필요합니다” 같은 의미상 표현을 사용했다. 정확히 “정보 확인 필요”라는 연속 문자열은 2/12 에만 있었다. A 는 이 표현 없이도 12/12 에서 정보 부재를 알렸다. 따라서 지정 표현의 유무 자체를 답변 정확성이나 규칙 효과로 간주하지 않는다.

4. 논의와 결론

4.1 가설을 어디까지 지지하는가

해석	A / B 오류	차이 A-B
기본: 단정 중심	3/20 / 2/20	5%p
넓은 해석: B-Q02 권고 포함	3/20 / 3/20	0%p
좁은 해석: 명시적 채널 약속만	1/20 / 1/20	0%p

기본 분석의 작은 차이는 가설 방향과 일치한다. 그러나 한 경계 문장의 판정을 바꾸면 차이가 사라지고, 구체 채널 약속만 세어도 차이가 없다. 따라서 가설을 확증하거나 “프롬프트를 추가하면 오류가 줄어든다”고 일반화하지 않는다. 두 조건이 언제나 동등하다는 결론도 아니다.

4.2 차이가 작았던 이유와 남은 오류

첫째, A 도 같은 공식 자료를 이미 제공받아 미확인 요구값의 보류율이 높았다(12/12). 둘째, 짧은 안내문과 직접적인 질문이 많고 여러 질문이 같은 주제를 공유해 추가 규칙의 이점이 드러나기 어려웠을 수 있다. 셋째, 기본 오류 5 개가 모두 최종 프로젝트 주제에서 발생했다. “아직 문서에 없다”는 설명 뒤에 친절한 후속 안내 약속을 덧붙이는 경향이 관측되었다. 두 번째·세 번째 설명은 가능한 원인이며 인과적으로 따로 시험한 것은 아니다.

서비스 기획 관점에서는 “질문에 모른다고 답했는가”만 검사하지 않고, 뒤에 붙는 일정·공지 채널·응답 보장도 근거와 대조해야 한다. 후속 규칙으로 안내 시행 약속까지 제한하는 방법을 제안할 수 있지만, 이번 실험에서 그 추가 규칙의 효과를 검증한 것은 아니다.

4.3 한계

표본은 한 가상 안내문과 임의 선정 질문 20 쌍이며, 동일 문항의 반복 생성은 없었다. 중복 주제를 포함해 40 응답을 40 개의 서로 독립적인 표본처럼 취급할 수 없다. 단일 모델 별칭, 서버 기본값, 비무작위 순서와 생성 설정의 영향도 분리하지 못했다. Q17 A/B 는 통신 중단으로 날짜가 달라졌다. B 는 추측 금지와 명시적 보류를 함께 추가하므로 두 지시와 프롬프트 길이의 효과를 따로 설명할 수 없다.

AI 보조 채점은 조건을 가리지 않았고 독립 인간 검토가 없다. 특히 향후 안내라는 관용 표현의 구체성 판단은 결과를 좌우한다. 민감도 분석은 이 불확실성을 드러내지만 평가자 편향을 제거하지는 않는다. 고객 만족도, 실제 운영 정확도, 다른 모델의 성능은 측정하지 않았다.

4.4 최종 결론

성공 응답 40 개에서 일반 프롬프트 A 와 근거 제한 프롬프트 B 는 알려진 정보를 답하고 미확인 요구값을 보류하는 데 모두 성공했다. 다만 자료에 없는 후속 안내를 덧붙이는 사례가 남았으며, 기본 판정의 오류율은 15%와 10%였다. 이 한 문항 차이는 경계 해석에 민감하므로 근거 제한 규칙의 안정적 우위를 확인했다고 결론내리지 않는다. 이번 연구의 의의는 실제 수집 자료를 보존하고, 핵심 답변의 보류와 답변 전체의 절차 단정을 분리해 검증할 수 있는 평가 구조를 만든 데 있다.

참고문헌

[1] Madhusudhan, N., Madhusudhan, S. T., Yadav, V., & Hashemi, M. (2025). Do LLMs Know When to NOT Answer? Investigating Abstention Abilities of Large Language Models. In Proceedings of the 31st International Conference on Computational Linguistics (pp. 9329–9345). Association for Computational Linguistics.
https://aclanthology.org/2025.coling-main.627/

[2] Peng, X., Choubey, P. K., Xiong, C., & Wu, C.-S. (2025). Unanswerability Evaluation for Retrieval Augmented Generation. In Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) (pp. 8452–8472). Association for Computational Linguistics.
https://doi.org/10.18653/v1/2025.acl-long.415
https://aclanthology.org/2025.acl-long.415/

재현 방법

ZIP 을 풀고 Python 3.9 이상에서 아래 명령을 실행한다. 분석에는 추가 패키지, 외부 계정, API 키, 네트워크 호출이 필요 없다. 수집 프로그램은 다시 실행하지 않는다.

py .\scripts\analyze.py --verify --out .\reproduced

원자료 41 행, 성공 40 개, 오류 1 개와 해시 검사를 확인한다. 기본 오류 A 3/20·B 2/20, 보조 지표 각 12/12, 경계 해석 별 3:3·1:1 이 같은 값으로 생성되면 계산이 재현된 것이다. 결과는 reproduced/summary.json 과 summary.csv 에 저장된다.

파일	확인할 내용
data/raw/	사용자 제공 원본 responses.jsonl·run_config.json
protocol/ · prompts/	가설·질문·정답 근거·변경 이력·실제 요청문
scoring/	응답별 원문·AI 보조 판정·경계 해석
scripts/analyze.py	자료 무결성 검증 및 저장된 채점의 재집계
results/	본문 표·그림의 숫자와 질문별 쌍 비교

계산의 재현은 의미 판정의 독립적 검증이 아니다. 원본 included_in_current_paper 플래그는 보존했으며 실제 포함 기준은 protocol/final_analysis_manifest.json 을 따른다.

AI 와 나의 판단

AI 에게 맡긴 일: 가설·고정 질문 설계, 자동 수집·재개 코드, 문헌 확인, 응답 의미의 보조 채점, 민감도 분석과 논문 편집을 도움받았다.

내가 직접 판단한 일: MOA 주제를 선택하고 자동화를 요청했다. 내 PC 에서 API 호출을 실행하며 오류·완료 로그를 확인하고 실제 수집 파일을 제공했다.

AI 제안을 따르지 않은 일: 질문을 계속 한 개씩 복사하는 대신 자동 수집을 요청했고, 잘못 전달된 Q09-B 를 실제 답변으로 정정했다. 모델을 바꿀 때는 기존 응답과 섞지 않고 별도 회차로 수집했다.